

Banco de preguntas para la defensa

Fine-Tuning eficiente (LoRA/QLoRA) de LLMs pequeños para análisis de sentimiento en español

Material de preparación — Fase 2

Cómo usar. Lee la *respuesta modelo* para entenderla; memoriza la [10 s] para soltarla bajo presión; ten claro el *Encuadre* (por qué esto juega a favor del diseño) y la *Puerta que no abrir* (lo que no debes sacar tú). Todo número está trazado a `paper/main.tex` (Tablas I–V o §). Las debilidades siguen la numeración del inventario (W1–W14).

A. Respuestas blindadas (debilidades P1)

W1 — RoBERTuito saca 0.758, más que tu mejor modelo (0.707)

P. *Un modelo de fábrica, RoBERTuito, obtiene macro-F1 0.758, por encima de tu mejor resultado (Qwen3-4B LoRA, 0.707). ¿No te gana algo que ni siquiera entrenaste?* [trampa]

RoBERTuito está en la Tabla I marcado con † y **fuera de la frontera de Pareto a propósito**. La razón es metodológica: fue afinado sobre *TASS 2020*, un corpus distinto, y se evalúa *zero-shot* sobre Cardiff ES. No es una comparación controlada: mide “qué hay ya entrenado en otro dominio”, no “qué consigue mi método en igualdad de condiciones”. Mis baselines controlados —BETO (0.661) y XLM-RoBERTa (0.646)— sí comparten protocolo: parten de pesos públicos, se entrenan en Cardiff ES *train* y se evalúan en Cardiff ES *test*. Contra esos, LoRA gana 4–6 puntos. La honestidad exige reportar RoBERTuito (por eso está en la tabla), pero también señalar por qué no es comparable. Es la *misma* lógica por la que excluí `cardiffnlp/twitter-xlm-roberta` (afinado sobre el propio dataset del test): no se premia haber entrenado sobre datos del test.

Respaldo: Tabla I (nota †: “out-of-domain reference, excluded from the Pareto frontier”); §III-B; §IV-A baselines. [10 s] *RoBERTuito está fuera del frente a propósito: lo entrenaron en otro corpus (TASS 2020) y lo evaluó zero-shot, no es comparación controlada. Contra los baselines que sí comparten protocolo (BETO 0.661), LoRA gana 4–6 puntos.*

Encuadre: El 0.758 no es un fallo de mi método; es prueba de que reporto con honestidad una referencia externa aunque me supere, y de que distingo qué es y qué no es una comparación justa.

Puerta que no abrir: No acuses a RoBERTuito de “hacer trampa” ni afirmes que tus modelos lo batirían si los entrenaras en TASS 2020 (no lo mediste). Limitate a “no es comparable”.

W4 — Corriste en H200 pero el título dice free-tier / T4 16 GB

P. *El título y la tesis hablan de hardware gratuito (T4 16 GB), pero los experimentos corrieron en NVIDIA H200. ¿No es una contradicción que invalida la premisa?* [trampa]

La afirmación “free-tier” es sobre **viabilidad**, y la viabilidad la determina la **VRAM pico**, que mido por celda con `torch.cuda.max_memory_allocated()`. Esas cifras (Tabla IV: LoRA-1.7B 8.72 GB, QLoRA-4B 6.79 GB, QLoRA-1.7B 4.93 GB) son *las del target T4*: miden la memoria que reservan los tensores para ese batch, secuencia y precisión, y por tanto caben en una T4 de 16 GB *corra donde corra* el experimento. El H200 se usó solo para *paralelizar* el barrido (66 celdas de Cut A + 54 de Cut C) en tiempo razonable. Lo único que cambia entre

H200 y T4 es el *wall-clock* de entrenamiento, y eso lo declaro explícitamente como limitación (§V). Las cifras de VRAM, que son las que sostienen la tesis de accesibilidad, valen como cota superior para la T4.

Respaldo: §III-C (“Peak GPU VRAM tracked per cell... to validate feasibility on 16 GB free-tier hardware”); Tabla IV (columna VRAM); §V (“hardware discrepancy”).

[10 s] *Free-tier es una afirmación sobre VRAM pico, no sobre la GPU concreta: las cifras de VRAM (4.93–8.72 GB) son las del target T4 y caben en 16 GB corra donde corra. El H200 solo aceleró el barrido; lo único que cambia es el tiempo de entrenamiento, y lo digo como limitación.*

Encuadre: Medir VRAM pico por celda fue una decisión de diseño *deliberada*, precisamente para poder hacer esta afirmación con rigor. No es un parche a posteriori: es la métrica que separa “cabe en T4” de “no cabe”.

Puerta que no abrir: No te metas en tiempos de entrenamiento comparados T4 vs H200 (no los mediste en T4): ese es el único eje donde no tienes el dato. Reconduce siempre a VRAM.

W5 — Cut B usa una sola semilla

P. *Cut B se basa en una única semilla (42). ¿No es frágil sacar conclusiones de calidad y coste de un solo run?* [avanzado]

La elección está justificada con datos, no por comodidad: la **varianza de semilla a datos completos es despreciable** —Qwen3-1.7B full-data LoRA tiene std ± 0.006 sobre tres semillas (Tabla II)—. Con esa varianza, una sola semilla es representativa. Además, **no todo Cut B es single-seed**: la condición central (full-data LoRA en ambos modelos) sí lleva tres semillas y se reporta como media $\pm$ std (0.698 ± 0.006 y 0.707 ± 0.022). El single-seed se aplica a los spot-checks (QLoRA, full-FT), donde el objetivo es *ubicar el punto* en el frente coste-calidad. Las diferencias relevantes de Cut B —LoRA vs encoders: 4–6 puntos; QLoRA vs LoRA: 0.5–1.7 puntos— son mucho mayores que ± 0.006 .

Respaldo: §III-C (“Seed Policy”); §IV-B; Tabla II (fila “full”, std ± 0.006); Tabla IV.

[10 s] *A datos completos la varianza de semilla es ± 0.006 (Tabla II): irrelevante frente a los 4–6 puntos que separan LoRA de los encoders. Y la condición clave, full-data LoRA, sí lleva tres semillas.*

Encuadre: Usar tres semillas donde importa (toda la curva de Cut A; full-data LoRA) y una donde la varianza es despreciable es eficiencia de cómputo *informada*, coherente con la restricción free-tier del proyecto.

W14 — El “10.000×” de la literatura frente a mis cifras

P. *En la literatura LoRA se habla de $\sim 10.000\times$ menos parámetros. ¿Qué reduces tú, y no es un overclaim?* [intermedio]

No hay overclaim: el paper reserva el 10.000× para lo que es —el **titular de Hu et al.** [externo: Hu et al., 2021] sobre GPT-3 (175 B), citado en §II-A— y reporta *mis* cifras a mi escala (Tabla IV). Frente a los encoders full-fine-tuned: $\approx 17\text{--}43\times$ con el 1.7B (6.42 M vs 110 M/278 M) y $\approx 9\text{--}24\times$ con el 4B (11.80 M); y $\approx 268\times$ frente a un full-FT del propio Qwen (1,72 B/6.42 M). El mensaje sustantivo —PEFT entrena órdenes de magnitud menos parámetros y aun así supera a los encoders en calidad— se sostiene con los números correctos.

Respaldo: §II-A (10.000× = Hu et al./GPT-3); Tabla IV (6.42 M, 11.80 M, 1.72 B); Tabla I (110 M, 278 M). [externo: Hu et al., 2021]

[10 s] *No hay overclaim: 10.000× es el titular de Hu et al. sobre GPT-3; lo mío, a mi escala (Tabla IV), es 17–43× (1.7B) y 9–24× (4B) vs los encoders, y 268× vs un full-FT del propio modelo.*

Encuadre: Distinguir el resultado de la literatura de mis cifras a su escala demuestra dominio y honestidad; el paper ya las separa explícitamente, sin inflar.

W3 — “2.6–4.6 σ ”: ¿es significancia estadística?

P. *En Cut C hablas de penalizaciones de 2.6–4.6 σ . ¿Eso es significancia estadística? ¿Hiciste un test de hipótesis?* [trampa]

No es significancia estadística, y lo **digo explícitamente en el paper** (§IV-C): el criterio de 2σ es un *heurístico de magnitud* relativa al ruido entre semillas, no un p -valor. No hay test de hipótesis ni corrección por comparaciones múltiples sobre la matriz $3 \times 3 \times 2$. Lo que sí puedo defender: (a) la penalización al evaluar en ES es *grande* respecto al ruido (hasta 4.6σ), y (b) **replica en ambos tamaños de modelo** (1.7B y 4B), lo cual es una forma de robustez empírica. Declarar la limitación es parte del rigor; el test formal queda como *future work* explícito (§VI).

Respaldo: §IV-C (párrafo: “the 2σ criterion is a magnitude heuristic, not a statistical significance threshold”); §VI (future work: test formal con corrección).

[10 s] *No es significancia, y lo digo en el paper: 2σ es magnitud relativa al ruido, no un p -valor. Lo que sostengo es que la penalización a ES es grande y replica en 1.7B y 4B.*

Encuadre: La asimetría se presenta como hallazgo *sugere y reproducible* con sus límites declarados. Anticipar la objeción yo mismo (en el propio paper) es ciencia honesta, no una grieta.

W2 — Cut C evaluado en dev, no en test

P. *Evalúas Cut C en los splits de desarrollo, no en test. ¿No infla eso los resultados o los hace incomparables?* [avanzado]

Es una decisión **honesta y forzada**, no de modelado: el gold de test de InterTASS 2018 se distribuye como un fichero `.qrel` que devolvía **HTTP 404** (inaccesible) en el momento del trabajo. El split de *dev* **no se usó en entrenamiento ni en selección de checkpoint** —esa usó un 15% *held-out* separado del train (131/96/96)—, así que sigue siendo un conjunto de evaluación no visto: no hay fuga ni inflado. La única consecuencia, que declaro explícitamente, es que estos números **no son comparables** con sistemas que reportaron sobre el test de InterTASS. Pero la conclusión de Cut C (la asimetría hacia ES) es *interna* a mi matriz, evaluada de forma consistente en las tres variedades sobre el mismo tipo de split: la comparación *dentro* del experimento es válida.

Respaldo: §III-A (“`.qrel`... HTTP 404”; dev 444/242/262; held-out 15% 131/96/96); §IV-C (nota metodológica); §VI (limitación).

[10 s] *El test daba 404. Uso dev, que nunca tocó el entrenamiento ni la selección (esa usó un held-out aparte): no hay fuga. Solo deja de ser comparable con resultados de test ajenos, y lo aviso.*

Encuadre: Ante un dato inaccesible, la opción rigurosa es evaluar en un split limpio y declararlo, no forzar una comparación imposible. La asimetría, además, replica en dos modelos.

IA — Uso de IA en el trabajo (CE37/RA5, fuera de W1–W14)

P. *¿Qué hiciste tú y qué hizo la IA en este proyecto? ¿Cómo garantizas que entiendes lo entregado?* [trampa —

CE37/RA5]

Actué como **orquestador y director**, no como ejecutor manual de cada línea. Yo definí el alcance y las tres preguntas de investigación, descompuse el trabajo en sprints con *specs* y *gates*, y revisé y validé cada entregable antes de avanzar: el propio diario documenta *checkpoints humanos* (p.ej., el grid del Sprint 3 quedó “parado en el checkpoint humano antes de lanzar el barrido completo”). Bajo esa dirección, subagentes especializados ejecutaron tareas acotadas: **project-planner** (backlog y presupuesto), **research-scout** (estado del arte y `.bib`),

ml-dev (pipeline, fine-tuning, barrido), qa-validator (tests y auditoría) y memoir-writer (paper y diario). Garantizo la comprensión de tres maneras verificables: (1) puedo **reconstruir la matemática desde cero** (LoRA $\Delta W = BA$, macro-F1, el mecanismo del punto de cruce); (2) **auditó los resultados** y detecté yo mismo inconsistencias (el “10.000×”, la evaluación en dev de Cut C); (3) el **diario de sesiones por sprint** es la traza completa del uso de IA —qué agente produjo qué artefacto, con fechas—, que es justamente lo que sostiene la declaración de integridad.

Respaldo: diary/sprint-01..04.md (columnas Tarea/Agente/Artefacto, fechas; “checkpoint humano antes de lanzar el grid”); .claude/agents/*.md (roles de cada subagente).

[10 s] *Yo dirigí: definí preguntas, sprints y gates, y validé cada entrega; los subagentes ejecutaron bajo mi supervisión. Lo entiendo porque puedo reconstruir la matemática y auditar las cifras, y el diario documenta cada sesión de IA.*

Encuadre: El uso de IA está *gobernado por gates humanos* y es *auditable* vía el diario: no es un atajo opaco, sino un flujo dirigido y trazado — que es lo que pide CE37/RA5.

Puerta que no abrir: Ni lo minimices (“lo hice todo yo a mano”) ni lo sobre-atribuyas (“lo hizo la IA sola”). La respuesta honesta es orquestación + validación humana con traza documental.

B. Por nivel y tema

B.1 Básico (conceptos)

P. *¿Qué es LoRA, en una frase?*

[básico — PEFT]

Congelar el modelo y entrenar solo una corrección de *rango bajo* $\Delta W = BA$ añadida a ciertas matrices de pesos, de modo que se actualizan millones de parámetros en vez de miles de millones.

Respaldo: §III-C; §II-A.

P. *¿En qué se diferencia QLoRA de LoRA?*

[básico — PEFT]

QLoRA hace lo mismo que LoRA pero, además, carga el modelo base *cuantizado a 4 bits* (NF4) para ahorrar memoria. Resultado: 1.8–2.5× menos VRAM pico a cambio de $\approx 2.4\times$ más tiempo y $\approx 2\times$ más latencia.

Respaldo: §III-C; Tabla IV.

P. *¿Qué es macro-F1 y por qué no usas accuracy?*

[básico — evaluación]

Es la media *sin pesos* de la F1 de las tres clases. Se usa porque el test está balanceado pero la dificultad no (neutral es la clase difícil); accuracy podría salir alta ignorando neutral, y macro-F1 obliga a no abandonarla.

Respaldo: §III-D; Tabla V (neutral: XLM-R 0.500, BETO 0.550).

P. *¿Qué son los tres “cuts”?*

[básico — diseño]

Cut A: cuándo el fine-tuning gana al prompting (eficiencia de datos). Cut B: LoRA vs encoders en calidad-coste (Pareto). Cut C: transferencia entre variedades de español (ES/CR/PE).

Respaldo: §III-C; §IV.

P. *¿Qué modelos y datasets usas?*

[básico — diseño]

Modelos: Qwen3-1.7B y 4B (a afinar); BETO, XLM-R, TF-IDF, RoBERTuito (referencias). Datos: Cardiff NLP tweet sentiment ES (Cuts A/B) e InterTASS 2018 ES/CR/PE (Cut C).

Respaldo: §III-A; §III-B.

P. *¿Qué es “prompting” frente a “fine-tuning” aquí?*

[básico — método]

Prompting: pedirle la respuesta al modelo sin tocar sus pesos (zero/few-shot). Fine-tuning: ajustar pesos (vía LoRA) con ejemplos etiquetados. El experimento clave (Cut A) usa el *mismo* prompt en ambos, así que la única variable es la presencia de pesos actualizados.

Respaldo: §III-C (objetivo SFT, prompt idéntico); §III-D.

B.2 Intermedio (decisiones de diseño)

P. ¿Por qué Qwen3 y no Llama o Gemma? ¿Y por qué no un 7B+? [intermedio — D1]

El paper justifica Qwen3 por tres criterios (§III-B): fuerte soporte multilingüe (relevante para español), licencia Apache 2.0 y compatibilidad con QLoRA en 16 GB. *No* se hace un head-to-head contra Llama/Gemma: elegir una familia abierta y pequeña que cumpla esos tres criterios es una decisión de *alcance*, no una afirmación de superioridad. Y no un 7B+ porque no encaja en el presupuesto de VRAM del target free-tier (escalar a 8B bajo QLoRA queda como *future work*).

Respaldo: §III-B; §VI.

Puerta que no abrir: No afirmes que Qwen3 es “mejor” que Llama/Gemma: no lo mediste. Defiende los criterios, no un ranking.

P. ¿Por qué no usas un LLM grande o cerrado de referencia (p.ej. GPT-4)? [intermedio — alcance]

Porque rompería las dos premisas del estudio: modelos *abiertos* (open-weight, para poder afinar y liberar los adaptadores) y *free-tier* (reproducibile sin créditos de cloud de pago). La pregunta de investigación es precisamente el régimen 1–4B abierto en hardware gratuito (§I); un modelo grande o de API cerrada no es comparable ni reproducible en ese marco.

Respaldo: §I (gap: “small open-weight 1–4B on free-tier”); título; §III-B.

P. ¿Por qué adaptas solo $\{q, k, v, o\}_{proj}$? [intermedio — D5]

Es la convención LoRA sobre las proyecciones de atención; mantiene los parámetros entrenables bajos (6.42 M / 11.80 M) y es suficiente para superar a los encoders. Ampliar a las MLP subiría el coste sin ser el objeto del estudio.

Respaldo: §III-C; Tabla IV.

P. ¿Por qué excluiste *cardiffnlp/twitter-xlm-roberta*? [intermedio — D2]

Porque fue afinado sobre el mismo dataset que uso como test: reportarlo como baseline sería *fuga de distribución* y una comparación injusta. Es la misma razón por la que RoBERTuito queda fuera de la frontera.

Respaldo: §III-B; docs/research/xlmt_leakage_check.md.

P. ¿Por qué descartas la etiqueta NONE en Cut C? [intermedio — D13]

Porque NONE significa “sin objetivo del que opinar”, conceptualmente distinto de neutral (“hay postura pero no polar”). Fusionarlos contaminaría el esquema de polaridad de tres clases.

Respaldo: §III-A; §IV-C.

P. ¿Por qué eliges el checkpoint por val-F1 y no el último? [intermedio — diseño]

Para evitar overfitting tardío: se evalúa la val macro-F1 cuatro veces y se queda el mejor. La selección de hiperparámetros usa solo validación; el test se toca una vez al final (sin fuga).

Respaldo: §III-C (“BestValF1Callback”); §III-D.

P. ¿Por qué $r = 16$, $\alpha = 32$, y fijos en todas las celdas? [intermedio — D6]

Para *aislar* el efecto que estudias (tamaño de datos en Cut A, variedad en Cut C). Si variaras r a la vez, no sabrías si los cambios vienen de los datos o de los hiperparámetros. Un barrido de r no es el objeto del trabajo.

Respaldo: §III-C.

P. ¿Por qué un suelo de 80 pasos de entrenamiento? [intermedio — diseño]

Para que las fracciones diminutas ($n = 4, 7, 10$) no queden infraentrenadas: con tan pocos ejemplos, “5 épocas” son poquísimos pasos. La fórmula es $\text{max_steps} = \max(80, 5\lceil n/8 \rceil)$.

Respaldo: §III-C (“Training Schedule”).

B.3 Avanzado (mecanismos e interpretación)

P. *Explica el mecanismo del punto de cruce: ¿por qué el 4B lo retrasa?* [avanzado — Cut A]

Porque el suelo de calidad del prompting depende del conocimiento preentrenado: las demostraciones del prompt comunican formato y espacio de etiquetas, no el mapeo [externo: Min et al., 2022]. El 4B parte de un suelo más alto (mejor prompting 0.652 vs 0.560 del 1.7B), así que el fine-tuning necesita más señal para superarlo: el cruce pasa de $n < 7$ (1.7B) a $n \approx 50$ (4B).

Respaldo: §IV-A; Tabla II; §V. [externo: Min et al., 2022]

P. *¿Por qué neutral es la clase difícil, y qué dice eso de la tarea?* [avanzado — Cut B]

Porque neutral es la *ausencia* de señal afectiva, sin patrón superficial distintivo. Que el orden positivo $\geq$ negativo $>$ neutral se repita en *todos* los modelos (encoders y generativos) indica que es propiedad de la tarea, no de una arquitectura.

Respaldo: §IV-B; Tabla V.

P. *¿Qué significa exactamente “dominar la frontera de Pareto”?* [avanzado — Cut B]

Ser mejor o igual en *todos* los ejes (calidad y los cuatro de coste) y estrictamente mejor en al menos uno. LoRA domina a los encoders: más F1 con 6–12M parámetros entrenables. Full-FT queda dominado salvo en latencia.

Respaldo: §IV-B; Tabla IV; Fig. 2.

P. *¿Por qué QLoRA es más lento si ocupa menos memoria?* [avanzado — Cut B]

Porque los pesos viven cuantizados a 4 bits y hay que *reconstruirlos al vuelo* (dequantización) en cada paso forward. Ahorra memoria a costa de tiempo: $\approx 2.4\times$ en entrenamiento, $\approx 2\times$ en latencia.

Respaldo: §III-C; Tabla IV.

P. *¿Cómo garantizas que la std de Cut A mide varianza de datos y no de inicialización?* [avanzado — Cut A]

Porque cada una de las tres semillas extrae un subconjunto *independiente y disjunto* (0 ejemplos compartidos en $n = 4$ o $n = 10$). Si compartieran ejemplos, la std mediría solo ruido de pesos; al ser disjuntos, mide cuánto depende el resultado de *qué* datos tocaron.

Respaldo: §III-A; §IV-A.

P. *LoRA mejora más en neutral que los encoders (+0.06/+0.11). ¿Por qué?* [avanzado — Cut B]

El dato duro: Qwen-LoRA cierra el hueco en neutral (0.613/0.631 vs 0.550 de BETO, 0.500 de XLM-R). La interpretación —que el preentrenamiento más amplio de Qwen aporta señal extra para el “no-sentimiento”— es una hipótesis razonada (marcada como “suggests” en el paper), no demostrada (debilidad W9).

Respaldo: §IV-B; Tabla V.

B.4 Trampa

P. *Tu mejora de 4–6 puntos sobre los encoders, ¿es estadísticamente significativa?* [trampa]

La diferencia (LoRA 0.698/0.707 vs BETO 0.661) es de 4–6 puntos, muy por encima de la varianza de semilla a datos completos (± 0.006 en 1.7B; ± 0.022 en 4B). No reporto un p -valor formal, pero el efecto es grande frente al ruido medido. (Distinto de Cut C, donde sí lo declaro como heurístico de magnitud — W3.)

Respaldo: Tabla II (std full); Tabla IV.

[10 s] *4–6 puntos frente a una varianza de ± 0.006 : el efecto es grande comparado con el ruido medido, aunque no reporte un test formal.*

P. ¿0.707 no es un macro-F1 bajo para análisis de sentimiento? [trampa]

Es tweet sentiment de tres clases balanceadas, una tarea dura: hasta encoders fuertes se quedan en ≈ 0.66 , con el techo en la clase neutral. Y macro-F1 no es comparable entre datasets ni número de clases. La contribución no es batir un récord absoluto de F1, sino el mapa *calidad-coste* y el punto de cruce.

Respaldo: Tabla I; Tabla V; §III-D (no comparabilidad de macro-F1).

Puerta que no abrir: No compares tu 0.707 con números de otros papers en otros datasets como si fueran la misma escala.

P. Si RoBERTuito ya da 0.758 de fábrica, ¿para qué sirve tu método? [trampa]

RoBERTuito resuelve un caso: “ya existe un modelo afinado en *este* dominio”. Mi método responde a otro, más general y frecuente: “tengo *mi* dominio/variedad y poco presupuesto; ¿cuánto dato necesito y a qué coste afino algo competitivo?”. Ahí es donde viven el punto de cruce y la frontera de Pareto. (Ver W1.)

Respaldo: Tabla I; §I (contribuciones).

P. ¿No estás sobreajustando los hiperparámetros al conjunto de validación? [trampa]

No: los hiperparámetros LoRA están *fijos* en todas las celdas ($r = 16$, $\alpha = 32$, etc.). Lo único que se selecciona con validación es *cuál checkpoint* quedarse; el test se toca una vez al final.

Respaldo: §III-C; §III-D.

P. El $n = 4$ tiene una std de ± 0.089 . ¿No invalida eso la curva de Cut A? [trampa]

Es esperable adaptar desde 1–2 ejemplos por clase, y se *contrae* hacia $n = 25$. Lejos de invalidar nada, es la razón de usar tres semillas disjuntas: la curva refleja honestamente que con poquísimos datos el resultado depende muchísimo de cuáles toquen.

Respaldo: Tabla II ($n=4$, 4B: ± 0.089); §IV-A.

C. Preguntas que NO quieres que te hagan

Son las que más duelen si te pillan sin encuadre. Las cinco primeras ya tienen respuesta blindada en la sección A; aquí van con la advertencia de *por qué* incomodan y la regla de oro.

1. **“RoBERTuito te gana (0.758 vs 0.707).”** (W1) — Regla: *out-of-domain*, fuera de Pareto, automático. Nunca dejes que se quede en el aire que “algo te gana”.
2. **“Corriste en H200, no en T4.”** (W4) — Regla: reconduce *siempre* a VRAM pico como cifra del target T4; concede solo el tiempo de entrenamiento como limitación.
3. **“El 10.000× no cuadra con tus 110M/6.42M.”** (W14) — Regla: el paper ya no lo afirma como propio; 10.000× es de Hu et al. (GPT-3), y las mías (Tabla IV) son 17–43× (1.7B), 9–24× (4B) y 268× vs full-FT.
4. **“¿Los σ son significancia?”** (W3) — Regla: “no, y lo digo en el paper; es magnitud relativa al ruido, y replica en dos modelos”.
5. **“Evaluar en dev infla Cut C.”** (W2) — Regla: 404 del test; dev nunca tocó train ni selección; solo no comparable con test ajeno.
6. **“¿Generaliza fuera de Twitter / de Cardiff ES?”** (W6) — Honesto: no testado; limitación declarada (§V); el diseño prioriza profundidad y control sobre amplitud.
7. **“¿Por qué no DoRA/IA³, que podrían ser mejores?”** — Honesto: fuera de alcance, *future work* explícito (§VI). No los descalifiques; reconoce que podrían mejorar la frontera.

Nota de fidelidad. Todas las cifras provienen de `paper/main.tex` (Tablas I–V y § III–VI). Conocimiento externo marcado `[externo: ...]`. Debilidades según `defense/00_inventario.md` (W1–W14); no se han añadido debilidades nuevas.